
Enquête sur les besoins à 8 en matière de Science Ouverte

Aymeric Luneau, BU Paris 8

Oct 09, 2026

CONTENTS

1	Profils des enquêtés	3
1.1	Les statuts représentés	3
1.2	Cultures épistémiques	3
1.3	Les lieux de travail	5
1.4	Les systèmes d'exploitation	8
1.5	Utilisation de l'IA	8
2	Connaissance et pratique de la Science Ouverte	11
2.1	Les besoins d'accompagnement à la Science Ouverte	13
2.2	Stockage, sauvegarde et archivage des données	15
3	Production et analyse des données	17
3.1	Types de données produites	17
3.2	Outils de traitement	17
3.3	Développement et dépôt de codes ou de logiciels	20
3.4	Accompagnements et formations méthodologiques	21
4	Le TGIR Huma-num et ses outils	29
5	Glossaire	33
6	Bibliographie	35
	Bibliography	37
	Index	39

Dans un contexte de transformation profonde des pratiques de recherche sous l'effet du numérique et du mouvement international en faveur de la science ouverte, l'université engage une démarche structurée de réflexion et d'action autour de la gestion, du partage et de la valorisation des productions scientifiques. Cette dynamique s'inscrit dans la volonté de construire, à moyen et long terme, une politique d'établissement cohérente en matière de science ouverte, fondée sur une compréhension fine des besoins de sa communauté et sur la mise en œuvre progressive d'une offre de services adaptée.

C'est dans ce cadre qu'une enquête est conduite auprès des chercheurs, des personnels de laboratoire et des doctorants, afin de mieux connaître leurs pratiques numériques, leurs environnements de travail et leurs besoins d'accompagnement et de formation autour de plusieurs thématiques clés :

- la science ouverte et ses principes ;
- le cycle de vie des données de la recherche (collecte, traitement, gestion, documentation, ouverture et partage) ;
- les pratiques de publication en accès ouvert et la diffusion des résultats scientifiques.

[Download PDF](#)

PROFILS DES ENQUÊTÉS

1.1 Les statuts représentés

Les personnes ayant répondu à l'enquête sont majoritairement des enseignants-chercheurs ou des chercheurs (87%), 10% d'entre elles sont des doctorants, tandis que les personnels d'appui à la recherche (ingénieur d'étude et de recherche) représentent 3% de l'effectif total.

Table 1.1: Le statut des répondants

q25_statut_rec	nb	freq
Chercheur	104	87,4
Doctorant	12	10,1
Personnel d'appui à la recherche	3	2,5
Total	119	100,0

1.2 Cultures épistémiques

1.2.1 Les laboratoires et les UFR représentés

Un peu moins de 50% des personnes interrogées ont accepté de donner des informations sur leur ufr ou laboratoire de rattachement. Ces informations ont été collectées à l'aide de la dernière question proposant aux participants de laisser leurs coordonnées afin de poursuivre les échanges ultérieurement (Fig. 1.1).

4/ Si vous souhaitez un suivi ou un échange à la suite de cette enquête, vous avez la possibilité de renseigner vos coordonnées ci-dessous :

Nom : _____

Prénom : _____

Adresse e-mail : _____

Votre UFR, département, laboratoire d'affiliation : _____

Fig. 1.1: Demande des coordonnées des personnes enquêtées

Étant donné que les réponses se présentent sous la forme de texte libre, nous les avons analysées à la main pour extraire le nom de l'UFR, du laboratoire, du département et parfois de l'école doctorale. Nous avons ensuite complété les données manquantes concernant les laboratoires et les UFR à partir d'informations trouvées sur le Web pour les répondants ayant

laissé leur prénom et nom. Grâce à ce travail, nous connaissons les affiliations d'une cinquantaine de personnes : 57 pour les laboratoires (Table 1.2) et 54 pour les UFR (Table 1.3).

Les laboratoires les plus représentés (Table 1.2) sont Paragraphe (7%), le Laboratoire d'économie dyonisien (LED, 6%), l'unité de recherche Fonctionnement et Dysfonctionnement Cognitifs (DYSCO, 4%), le LADYSS (3%) et le Centre d'études sur les médias, les technologies et l'internationalisation (CEMTI, 3%). Mis à part le DYSCO, ce sont quatre laboratoires au sein desquels la bibliothèque dispose de "référénts données". Concernant les UFR (Table 1.3), celui de psychologie est le plus représenté avec 13 personnes, soit 10% des répondants. 4% des répondants sont rattachés à l'UFR Erites (études, recherche et ingénierie en territoires – environnements – sociétés). On compte la même proportion pour les UFR AES économie-gestion et Textes et sociétés.

Table 1.2: Les laboratoires représentés

labo	nb	freq
paragraphe	8	6.7
led	7	5.9
dysco	5	4.2
ladyss	4	3.4
cemti	4	3.4
lapps	3	2.5
transcrit	3	2.5
chart	3	2.5
aiac	3	2.5
idhes	3	2.5
liasd	2	1.7
sfl	2	1.7
crespapa	2	1.7
circeft	1	0.8
arscan	1	0.8
crjp8	1	0.8
laboratoire d'études romanes	1	0.8
ihtp	1	0.8
legs	1	0.8
liage	1	0.8
musidanse	1	0.8
Non réponse	62	52,1

Table 1.3: Les UFR représentés

ufr	Effectifs absolus	Fréquences relatives
psychologie	13	10,9
erites	5	4,2
aes economie gestion	5	4,2
textes et sociétés	5	4,2
llce lea	4	3,4
culture et communication	4	3,4
arts	4	3,4
mitsic	4	3,4
sdl	2	1,7
sepf	2	1,7
droit	1	0,8
iut tremblay-en-france	1	0,8
iee	1	0,8
mitsic	1	0,8
le	1	0,8
Non réponses	65	54,6
Total	119	100,0

1.2.2 Champs disciplinaires

Nous avons également demandé aux participant de préciser leurs champs de recherches à l'aide de la nomenclature définie par l'European Research Council (ERC). Cette nomenclature compte 22 modalités.

Sans surprise pour une université ancrée dans les sciences humaines et sociales, 92% des répondants appartiennent à un champ des “sciences sociales et humaines” et plus de la moitié s'inscrivent dans le champ intitulé “SH3 Le mond social et ses interactions” (Fig. 1.3). On observe aussi la présense des sciences informatiques et des mathématiques, ainsi que des neurosciences.

1.3 Les lieux de travail

Afin de connaître les pratiques de travail des répondants, nous leur avons d'abord demandé où ils travaillaient le plus souvent en classant par ordre de priorité les trois modalités suivantes :

- “À mon domicile”
- “Dans mon bureau sur site”
- “Autre”

71% des personnes interrogées ont cité leur domicile en premier (Table 1.4). Le domicile constitue par ailleurs un lieu de travail pour 90% des répondants, quelque soit l'ordre dans lequel il a été placé. En comparaison, le “bureau sur site” arrive en première position dans 24% des cas et il est utilisé comme lieu de travail par 59% des répondants.

Parmi les autres lieux cités, on trouve tout d'abord les bibliothèques et les sites d'autres organisation (CNRS, Campus Condorcet, partenaires de recherche). Plusieurs répondants ont également indiqué qu'ils travaillaient “un peu partout”, faute de bureaux disponibles sur le campus.

“Où je peux, puisque nous n'avon pas de bureaux.”

“Dans les bureaux de collègues dans d'autres universités”

“Au bureau de la MSH ou à la bibliothèque. Mais je manque cruellement d'un espace de travail.”

1/ Votre/vos champ(s) principaux de recherche ? Catégories issues de la nomenclature ERC

- ☐ SH1 Individus, marchés et organisations
- ☐ SH2 Institutions, gouvernance et systèmes juridiques
- ☐ SH3 Le monde social et ses interactions
- ☐ SH4 L'esprit humain et sa complexité
- ☐ SH5 Textes et concepts
- ☐ SH6 L'étude du passé humain
- ☐ SH7 Mobilité humaine, environnement et espace
- ☐ SH8 Études des cultures et des arts
- ☐ PE1 Mathématiques
- ☐ PE2 Constituants fondamentaux de la matière
- ☐ PE3 Physique de la matière condensée
- ☐ PE4 Chimie physique et analytique
- ☐ PE5 Chimie de synthèse et matériaux
- ☐ PE6 Sciences informatiques et informatique
- ☐ PE7 Ingénierie des systèmes et de la communication
- ☐ PE8 Ingénierie des produits et des procédés
- ☐ PE9 Sciences de l'Univers
- ☐ PE10 Sciences du Système Terre
- ☐ PE11 Génie des matériaux
- ☐ LS1 Molécules de la vie
- ☐ LS2 Biologie intégrative
- ☐ LS3 Biologie cellulaire, du développement, cellules souches et régénération
- ☐ LS4 Physiologie de la santé, de la maladie et du vieillissement
- ☐ LS5 Neurosciences et troubles du système nerveux
- ☐ LS6 Immunité, infection et immunothérapie
- ☐ LS7 Prévention, diagnostic et traitement des maladies humaines
- ☐ LS8 Biologie environnementale, écologie et évolution
- ☐ LS9 Biotechnologie et ingénierie des biosystèmes

Si vous le souhaitez, vous pourrez renseigner en fin d'enquête, votre rattachement à une UFR, un département, un laboratoire.

Fig. 1.2: Les champs de recherche, une question à choix multiples




Fig. 1.3: Les champs de recherche des répondants

“Où je peux, je n’ai pas de bureau à la fac (15 m2 pour 6 titulaires).”

Ces réactions recoupent les résultats observés concernant les services à développer, puisque 80% des répondants estiment qu’il serait utile de développer des espaces de travail (Fig. 3.8).

Table 1.4: Où travaillez-vous le plus souvent ?

Lieu de travail	Rang	Effectifs	fréquences (% , total des répondants)
A mon domicile	Tous rangs confondus	108	90,76
	1	85	71,43
	2	20	16,81
	3	3	2,52
Dans mon bureau sur site	Tous rangs confondus	70	58,82
	1	29	24,37
	2	36	30,25
	3	5	4,20
Autre, précisez	Tous rangs confondus	31	26,05
	1	5	4,20
	2	12	10,08
	3	14	11,76

1.4 Les systèmes d'exploitation

Les systèmes d'exploitation les plus répandus sont Apple et Windows. Seules 8 personnes utilisent Linux. En ce qui concerne les navigateurs, Firefox est le plus populaire. Il est cité par 52% des répondants. Chrome vient ensuite avec 23% des répondants qui l'utilisent.

Table 1.5: Les systèmes d'exploitation utilisés

Systèmes d'exploitation	Effectifs	Frequences (%)
Apple	53	44,5
ChromeOS	4	3,4
Linux	8	6,7
Windows	54	45,4
Total	119	100,0

Table 1.6: Les navigateur Web

Navigateurs	Effectifs	Frequences (%)
Firefox	62	52,1
Chrome	28	23,53
Safari	17	14,29
Autre, précisez	6	5,04
Chromium	3	2,52
Tor browser	2	1,68
Edge	1	0,84
Total	119	100,00

1.5 Utilisation de l'IA

68 répondants (soit 57%) disent avoir recourt à l'intelligence artificielle pour leurs recherches, dont 65% utilisent des versions gratuites. La même proportion cite Chat GPT. Il est l'outil le plus utilisé.

Table 1.7: Les 5 premiers outils IA les plus cités. Les pourcentages sont établis sur les 65 personnes ayant recourt à l'IA

Outils IA	nb	total	freq
chatgpt	42	65	64,6
claude	19	65	29,2
deepl	7	65	10,8
gemini	7	65	10,8
mistral	6	65	9,2

67 de ces 68 personnes ont ensuite répondu à la question “pourquoi les utilisez-vous?”. Une première lecture des réponses nous a permis de constater que les répondants mobilisaient parfois plusieurs raisons pour justifier leur utilisation de l'intelligence artificielle. Il nous a alors semblé intéressant de recourir à un algorithme de “topic modeling” afin d'identifier les “répertoires de motifs” idéaltypiques. L'algorithme choisi est BERTopic [Grootendorst, n.d.]. S'appuyant sur des modèles de plongement de mots (*word embedding*) de type sentence-transformers, BERTopic est réputé pour être plus performant que des modèles traditionnels comme le *Latent Dirichlet Allocation* (LDA) lorsqu'il s'agit d'extraire des

thématiques à partir d'un corpus de phrases courtes. Ce qui est le cas ici puisque la réponse la plus longue apportée à la question "pourquoi les utilisez-vous ?" est de 37 mots.

Une fois le plongement de mot effectué à partir d'un modèle pré-entraîné, l'algorithme BERTopic réduit la dimensionnalité de l'embedding avec UMAP et extrait les clusters (groupe de réponses) avec la méthode HDBSCAN. Pour finir, l'algorithme propose une labellisation en prenant les termes les plus spécifiques de chacun des clusters. Cette spécificité est calculée via un dérivé du TF-IDF (*Term frequency-inverse document frequency*) où l'"unité de référence" n'est plus le document, mais le cluster.

Le détail du traitement effectué est disponible ici : https://github.com/luneauaymeric/enquete_SO_p8/blob/main/script_traitement/topic_modeling.ipynb

Les 6 raisons d'utiliser l'IA




Fig. 1.4: 6 raisons d'utiliser l'IA

L'analyse fait ressortir six raisons "idéaltypiques" avancées par les personnes enquêtées pour expliquer leur utilisation de l'IA. La raison qui revient le plus souvent est le "gain de temps", que ce soit pour rédiger des e-mails, effectuer des tâches administratives ou rechercher de l'information :

"Pour gagner du temps sur des procédures routinières ou pour formaliser des courriels ou autres plus rapidement"

"Pour gagner du temps dans la recherche informations"

Les deux autres principales raisons sont :

- l'aide à la traduction ;
"relecture de l'anglais principalement"
- Le traitement et l'analyse des données ;
analyse et visualisation des données

analyse d'entretiens, recherche dans de multiples entretiens

L'IA est enfin utilisée pour :

- relire et corriger des textes;

Relectures, améliorations du manuscrit

- préparer des cours ou contrôler son utilisation par les étudiants ;

Enseignement: Structuration de cours, élaboration de syllabus, idées d'activités pédagogiques

- comprendre ce que ces outils font ;

J'essaye de comprendre comment ils fonctionnent

Bien sûr, plusieurs raisons peuvent apparaître au sein d'une même réponse. Par exemple, un des répondants a écrit :
"NoScribe en local pour des **transcriptions d'entretiens** et deepl pour des **traductions courtes et ponctuelles**".

CONNAISSANCE ET PRATIQUE DE LA SCIENCE OUVERTE

Les connaissances et les pratiques de la Science Ouverte constituaient le thème central de l'enquête. La première question évaluait ainsi le degré de familiarité des participants concernant les principes de la Science Ouverte (Table 2.1). 56% ont répondu "oui, un peu", 32% "oui, tout à fait" et 12% "non".

Table 2.1: Connaissance des principes de la Science Ouverte

Principes de la science ouverte	nb	freq
Non	14	11,8
Oui, tout à fait	38	31,9
Oui, un peu	67	56,3
Total	119	100,0

Les questions suivantes portaient sur le dépôt dans HAL, la publication de ressources via Octaviana et la diffusion des données de recherche. Le dépôt dans HAL apparaît être la pratique la plus répandue (Table 2.2). 35% des répondants disent déposer à chaque fois leurs productions scientifiques sur la plateforme et 40 % l'ont fait plusieurs fois. Sans surprise, les doctorants sont surreprésentés parmi les "non déposants" dans HAL lorsque l'on compare les différents statuts (Table 2.3). On observe toutefois que 10% des chercheurs ayant répondu à l'enquête disent n'avoir jamais effectué de dépôt sur HAL.

Table 2.2: Le dépôt dans HAL

Dépôt dans Hal	nb	freq
Non	15	12,6
Oui, plusieurs fois	48	40,3
Oui, systématiquement	41	34,5
Oui, une fois	15	12,6
Total	119	100,0

Table 2.3: La proportion de déposants dans HAL en fonction du statut

Statut	Non	Oui, plusieurs fois	Oui, systématiquement	Oui, une fois	Total
Chercheur	9,6	40,3	38,5	11,5	100,0
Doctorant	41,7	33,3	0,0	25,0	100,0
Personnel d'appui à la recherche	0,0	66,7	0,3	0,0	100,0
Total	12,6	40,3	34,5	12,6	100,0

En comparaison des dépôts dans HAL où 87% des répondants l'ont fait au moins une fois, ils ne sont plus que 28% à "avoir déjà diffusé leurs données de recherche une fois le projet terminé" (Table 2.4). On retrouve la même proportion au sein de la population des chercheurs : 30% d'entre eux ont déjà diffusé leur données (Table 2.5). Tandis que 90% des doctorants

ne l'ont jamais fait. On notera par ailleurs que la diffusion des données ne signifie pas nécessairement que celles-ci ont été ouvertes selon les principes FAIR (Facile à trouver, Accessible, Interopérable, Reproductible). Par exemple, le partage de données via une clé usb ou un site web personnel ne répondent pas deux premiers principes.

Les répondants pouvaient choisir plusieurs modalités de diffusion parmi les quatre options proposées. Cinq personnes (4%) disent avoir utilisé Nakala, quatre (3%) ont des données sur Zenodo et une seulement en entrepose sur Data Paris 8. Les autres modalités les plus citées (Fig. 2.1) sont Open Science Framework (N=10, 8%), les sites web personnels (N=6, 5%), les dépôts "git" (N=2, 2%) et les entrepôts spécialisés Ortolang (N=2, 2%) et Cocoon (N=1, 1%).

Table 2.4: La diffusion des données

Ouverture des données	nb	total	freq
Non	86	119	72,3
Autre, précisez	24	119	20,7
Oui, sur Nakala	5	119	4,2
Oui, sur Zenodo	4	119	3,4
Oui, sur Data Paris 8	1	119	0,8

Table 2.5: La diffusion des données en fonction du statut

Statut	Non	Oui	Total
Chercheur	71,2	28,8	100
Doctorant	91,7	8,3	100
Personnel d'appui à la recherche	0,0	100,0	100
Total	71,4	28,6	100




Fig. 2.1: Les modes d'ouverture des données

Concernant Octaviana (Table 2.6), 11 répondants (9%) ont déposé des ressources sur la bibliothèque numérique. Cinq d'entre eux ont mis des publications. Ils sont cinq répondants également à avoir déposé des travaux universitaires et trois ont publié des captations d'événements. En tout une personne interrogée sur cinq n'a jamais entendu parlé d'Octaviana.

Table 2.6: Le dépôt dans Octaviana

Dépôt sur Octaviana	nb	freq
Non	108	90,8
Oui	11	9,2
Total	119	100,0

2.1 Les besoins d'accompagnement à la Science Ouverte

Les besoins d'accompagnement exprimés par les répondants reflètent leur degré de familiarité avec les sujets proposés. En effet, 70% des personnes interrogées jugent utile l'accompagnement à l'ouverture des données selon les principes FAIR contre 32% pour l'accompagnement au dépôt des publications dans HAL (Fig. 2.2).

Nous pouvons relier ces différences de proportion au fait que la bibliothèque a mis en place des accompagnements et des formations à HAL depuis plus de six ans. Ces dispositifs participent de la mise en oeuvre du premier *Plan national pour la Science Ouverte* (2018-2021), lequel mettait l'accent sur l'ouverture des productions scientifiques. Les chercheurs ont été d'autant plus incités à signaler leurs publications, à défaut de les ouvrir totalement, que le Haut comité pour l'évaluation de la recherche et de l'enseignement supérieur (HCERES) prend en compte la liste des références présentes dans HAL pour évaluer les unités de recherche. La plateforme HAL est ainsi devenue un objet du quotidien des chercheurs. À l'inverse, instituée par la Directive européenne et mise en avant dans le second Plan national pour la Science Ouverte (2021-2024), l'ouverture des données est un sujet relativement nouveau et les formations proposées par la bibliothèque sur ce sujet sont plus récentes.




Fig. 2.2: Utilité des accompagnements à la Science Ouverte

q8_ter

	accomp_name	interet_accomp	cum_sum \
23	Choix des licences de diffusion	Non, pas utile	100.000000
21	Choix des licences de diffusion	Oui, très utile	74.789916

(continues on next page)

(continued from previous page)

22	Choix des licences de diffusion	Oui, plutôt utile	44.537815
11	Fairiser les données	Non, pas utile	100.000000
9	Fairiser les données	Oui, très utile	68.907563
10	Fairiser les données	Oui, plutôt utile	52.100840
20	Connaître les standards de métadonnées	Non, pas utile	100.000000
18	Connaître les standards de métadonnées	Oui, très utile	66.386555
19	Connaître les standards de métadonnées	Oui, plutôt utile	44.537815
8	Respecter le RGPD	Non, pas utile	100.000000
6	Respecter le RGPD	Oui, très utile	65.546218
7	Respecter le RGPD	Oui, plutôt utile	42.016807
5	Rédiger un PGD	Non, pas utile	100.000000
3	Rédiger un PGD	Oui, très utile	63.025210
4	Rédiger un PGD	Oui, plutôt utile	39.495798
2	Rédiger un data paper	Non, pas utile	100.000000
0	Rédiger un data paper	Oui, très utile	57.142857
1	Rédiger un data paper	Oui, plutôt utile	38.655462
17	Déposer des données	Non, pas utile	100.000000
15	Déposer des données	Oui, très utile	55.462185
16	Déposer des données	Oui, plutôt utile	39.495798
14	Dépot sur Hal	Non, pas utile	100.000000
12	Dépot sur Hal	Oui, très utile	31.932773
13	Dépot sur Hal	Oui, plutôt utile	22.689076

	nb	Oui
23	0.252101	0.747899
21	0.302521	0.747899
22	0.445378	0.747899
11	0.310924	0.689076
9	0.168067	0.689076
10	0.521008	0.689076
20	0.336134	0.663866
18	0.218487	0.663866
19	0.445378	0.663866
8	0.344538	0.655462
6	0.235294	0.655462
7	0.420168	0.655462
5	0.369748	0.630252
3	0.235294	0.630252
4	0.394958	0.630252
2	0.428571	0.571429
0	0.184874	0.571429
1	0.386555	0.571429
17	0.445378	0.554622
15	0.159664	0.554622
16	0.394958	0.554622
14	0.680672	0.319328
12	0.092437	0.319328
13	0.226891	0.319328

2.2 Stockage, sauvegarde et archivage des données

Le stockage, la sauvegarde et l'archivage renvoient à des temps différents du cycle de la donnée. Le stockage correspond au moment où les données sont exploitées. Au contraire l'archivage intervient après la phase de traitement et d'analyse, dans un moment où les données ne sont plus manipulées. Enfin, la sauvegarde est une mesure visant à garantir la sécurité et l'intégrité des données. Il est ainsi recommandé de copier ses données sur trois supports différents. Il est toutefois possible que les différences entre ces trois concepts ne soient pas connues de tous.

50% des personnes interrogées ont cité au maximum trois supports de stockage. Concernant la sauvegarde des données, le nombre médian est de deux : 50% des personnes interrogées ont cité au maximum deux supports de sauvegarde. La clé usb ou le disque dur externe sont les supports les plus utilisés que ce soit pour le stockage (67%), la sauvegarde (66%) ou l'achivage (66%). Concernant les clouds, ce sont les services commerciaux (Google, Icloud) qui arrivent en tête. 49% des répondants disent stocker ou sauvegarder leurs documents sur ces services et 42% les emploient comme espaces d'achivage. À l'opposé, seulement 9% des personnes interrogées recourent au cloud de Paris 8 (5% si on parle de sauvegarde ou d'archivage).




Fig. 2.3: Les lieux de stockage, de sauvegarde et d'archivage des données

PRODUCTION ET ANALYSE DES DONNÉES

3.1 Types de données produites

Les personnes interrogées travaillant exclusivement avec des données dites “quantitatives” sont 16% (Table 3.1). Elles sont 48% à s’appuyer essentiellement sur des données qualitatives et 36% à manipuler les deux types de données.

Table 3.1: Données qualitatives ou quantitatives ?

	nb	freq
Des données qualitatives	57	47,9
Des données quantitatives	19	16,0
Les deux	43	36,1
Total	119	100,0

Les quatre types de données les plus fréquemment produites (Fig. 3.1) sont les entretiens (61%), les données textuelles ou documentaires (58%), les données d’enquête (53%) et les données expérimentales ou d’observation (52%). On notera toutefois le caractère ambigu de certaines catégories. Ainsi la notion d’“enquête” est largement utilisée en sciences sociales pour désigner la partie empirique des recherches et peut renvoyer aussi bien aux méthodes d’enquête ethnographique qu’aux méthodes d’enquête par questionnaire. De même, les données d’observation peuvent se comprendre au sens de l’anthropologue qui observe les interactions au sein d’un groupe humain ou de l’ornithologue qui compte les espèces d’oiseau. Parmi les “autres types de données”, une personne a d’ailleurs précisé qu’il s’agissait d’“observations in situ non expérimentales”. Tandis qu’une autre ne se reconnaît pas dans la notion de “données”.

3.2 Outils de traitement

Le graphique (Fig. 3.2) donne à voir les réponses à la question “Quels langages de programmation ou logiciels de traitement de données utilisez-vous?”. 66% des personnes interrogées utilisent Excel. On retrouve ensuite les langages R (32% des répondants) et Python (19%). Les logiciels de statistique Stata (3%) et SAS (3%), ainsi que le langage Julia (2%) sont plus confidentiels. On remarque par ailleurs que 31% des répondants ont recouru à d’autres outils que ceux proposés dans la question.

Ces répondants ont complété leur réponse en donnant le nom de ces autres langages et logiciels. En tout, 26 outils ont été cités. Nous les avons regroupé en sept “familles”:

1. les “logiciels de statistiques” comme SPSS, Jamovi, Stata ;
2. les langages de “scripts et de programmations” comme Matlab ou C++. Probablement qu’une subdivision de cette catégorie serait justifiée afin de distinguer les langages généralement employés pour l’analyse de données (R, Julia, Matlab, Python) et les langages de programmation comme C++ ;




Fig. 3.1: Les types de données traitées




Fig. 3.2: Quels langages de programmation/logiciels de traitement de données utilisez-vous ?

3. les outils de gestion de bibliographie (Zotero, Endnote) ;
4. les logiciels de “tableurs” et les feuilles de calculs : Excel, Libre Calc ;
5. les langages liés au développement web (css, html, php, javascript) ;
6. les outils d’analyse textuelle (Iramuteq, ActiveTigger) ;
7. les “CAQDAS” (Computer-Assisted Qualitative Data Analysis Software) comme Nvivo, Qualcoder, Atlas.ti

Sur le graphique ci-dessous Fig. 3.3, nous n’avons affiché que les programmes cités par deux personnes au moins. Jamovi (8%) est le plus utilisé. Il s’agit d’un logiciel d’analyse statistique open source à la différence de SPSS qui est propriétaire. SPSS est cité par 3% des répondants. comme Nvivo (N=6) pour les logiciels CAQDAS.

On note enfin que 13% des personnes interrogées disent n’utiliser aucun outil informatique pour traiter les données.




Fig. 3.3: Logiciels cités par deux répondants ou plus.

3.3 Développement et dépôt de codes ou de logiciels

Parallèlement à l'utilisation d'outils informatiques pour le traitement des données, 27% des répondants ont déjà été amenés à développer ou faire développer du code ou des logiciels dans le cadre de leurs recherches.

Table 3.2: Les utilisateurs de langages informatiques ne développent pas tous du code. Le tableau indique que sur 51 personnes déclarant utiliser des langages de programmation (R, Python, C++, etc.), 26 considèrent qu'ils ne développent pas de code.

	N'utilise pas de langage de programmation	Utilise des langages de programmation	Total
Ne développe pas de code	61 (51,26%)	26 (21,85%)	87 (73,11%)
Développe du code	7 (5,88%)	25 (21,01%)	32 (26,89%)
Total	68 (57,41%)	51 (42,86%)	119 (100%)

Sur les 32 personnes ayant répondu “Oui” à la question “êtes-vous amené.e à développer ou faire développer des logiciels/du code spécialisé(s) ?”, 31 ont donné des indications sur ce qu'elles développent ou font développer (Table 3.3). Après une analyse manuelle des réponses, nous en avons classé 15 (soit 48% des 31 réponses) dans la catégorie “traitement et analyse de données”. Sept exemples (23% des 31 réponses) concernent la collecte de données d'expérience via, par exemple, le logiciel Psytoolkit. Tandis que 8 répondants (26% des 31 réponses) parlent de logiciels variés, d'algorithmes, de plateformes sans préciser la finalité du code.

Table 3.3: Types de code développé

Type de développement	nb	total	freq
traitement et analyse de données	15	31	48,4
programmes et logiciels variés	8	31	25,8
collecte de données	7	31	22,6
diffusion	2	31	6,5

Il est intéressant de noter que le recours à un langage de programmation ne suffit pas pour se considérer comme “développeur”. En effet, le tableau croisé Table 3.2 montre que 26 des 51 répondants manipulant des langages de programmation ou des scripts (R, Python, C++) disent ne pas développer de code. Cette proportion est plus forte chez les utilisateurs de “R” que de Python. 63% des premiers ne développent pas de code contre 30% pour les seconds (Table 3.4).

Table 3.4: Les utilisateurs de R et de Python et le développement de code

	Total	N'utilise pas R	Utilise R	N'utilise pas Python	Utilise Python
Ne développe pas de code	73,11	77,78	63,16	83,33	30,43
Développe du code	26,89	22,22	36,84	16,67	69,57
Total	100,00	100,00	100,00	100,00	100,00

En tout, 30 personnes — soit 25% des 119 participants à l'enquête et 94% des répondants développant du code — ouvrent leurs codes et logiciels quelque soit le mode d'ouverture choisi. Cette proportion est de 34% chez les utilisateurs de R contre 70% pour Python Table 3.5. Des chiffres similaires à ceux observés dans le tableau Table 3.4. Nous pouvons alors

faire l'hypothèse que l'écart observé entre le recours aux langages informatiques et le développement de code est lié au fait pour les chercheurs de se sentir légitimes à ouvrir leurs scripts.

Table 3.5: Les utilisateurs de R et de Python et l'ouverture du code

	Total	N'utilise pas R	Utilise R	N'utilise pas Python	Utilise Python
Ne développe pas de code	74,79	79,01	65,79	85,42	30,43
Développe du code	25,21	20,99	34,21	14,58	69,57
Total	100,00	100,00	100,00	100,00	100,00

Si nous regardons maintenant comment les 30 répondants ouvrent leurs codes, on note que 77% d'entre eux (19% des personnes interrogées) ont déjà fait des dépôts sur Github et 40% (10% des personnes interrogées) sur des instances Gitlab. Ils sont par ailleurs 5% à utiliser d'autres solutions, en complément ou non des deux premières. Ces solutions sont :

- Le dépôt *Statistical Software Components* (SSC) des commandes Stata;
- Les dépôts personnels;
- HAL;
- Ortolang et Huma-Num ;
- L'Institut national pour la propriété intellectuelle

Table 3.6: Les modalités d'ouverture du code et des logiciels

q7_software_depot	Effectifs	Total	Fréquences relatives (%)
0 Non	89	119	74,79
1 Oui, sur GitHub	23	119	19,33
2 Oui, sur GitLab	12	119	10,08
3 Oui, autre, précisez	6	119	5,04
4 Oui, sur Software Heritage	1	119	0,84

3.4 Accompagnements et formations méthodologiques

3.4.1 Méthodes

L'intelligence artificielle est la thématique pour laquelle un accompagnement est le plus demandé : 40% des répondants en ressentent le besoin à un niveau débutant et 16% à un niveau avancé. L'accompagnement à l'utilisation d'outils de webscrapping vient ensuite avec 47% des répondants qui le considèrent comme utile (35% à un niveau débutant et 12% à niveau avancé). Concernant, les méthodes spécifiques comme l'analyse textuelle et l'analyse de réseau, nous observons un taux identiques de personnes interrogées souhaitant un accompagnement à un niveau débutant. En revanche, la demande pour un accompagnement à l'analyse textuelle à un niveau avancé est un peu plus élevée (14%) que pour l'analyse de réseau.

En bas du tableau nous retrouvons le thème des statistiques descriptives avec 25% des répondants qui jugent utile un accompagnement sur ce sujet.




Fig. 3.4: Ressentez-vous le besoin d'un accompagnement méthodologique

3.4.2 Outils

```
q16_ter["cum_sum"] = q16_ter["cum_sum"] * 100
```

Les questions concernant les besoins d'accompagnement à différents types de logiciels open source a été posé deux fois :

- question 7, partie “Gestion et traitement des données”
- la question 3 de la partie “Analyse des données”.

La comparaison des tris à plat montre que certaines personnes ont répondu différemment. La différence reste néanmoins marginale. Par exemple, la première fois que la question a été posée, 39 personnes ressentaient le besoin d'être accompagné pour utiliser un tableur contre 30 la seconde fois que la question a été posée (Table 3.7).

Table 3.7: Besoin d'accompagnement pour l'utilisation de tableur: comparaison des réponses 1 et 2

Tableur	Réponse 1	Réponse 2
Non	80	89
Oui, avancé	23	16
Oui, débutant	16	14
Total	119	119

Dans l'ensemble, entre 50 et 80% des répondants ne ressentent pas le besoin d'un accompagnement méthodologique pour les différents logiciels cités (Fig. 3.5). Les quatre premier types de logiciel demandés sont :

1. les logiciels d'analyse textuelle. 48% des répondants disent ressentir le besoin d'un accompagnement (35% à un niveau débutant et 13% à un niveau avancé). À noter que les logiciels cités renvoient à des approches et des méthodes d'analyse différentes.
2. les logiciel d'analyse statistique (40%)
3. les logiciels d'analyse de données qualitatives, appelés aussi CAQDAS, comme Qualcoder (environ 37%)
4. le langage python (environ 35%)

Ensuite, on observe des besoins d'accompagnement pour les logiciels liés à gestion de bases de données (32%), à l'analyse de réseaux (31%) et la cartographie (29%).




Fig. 3.5: Besoin d'accompagnement aux outils open source

Dans le cas des besoins en accompagnement à la prise en main de logiciels propriétaires, 5 “familles” de logiciels étaient proposées :

- Les tableurs représentés par Excel
- les logiciels de traitements statistiques comme SPSS, Stata, SAS
- les logiciels de traitement des données textuelles avec Atlas.ti
- les systèmes d'information géographique via ArcGis
- les logiciels d'analyse des données qualitative (CAQDAS, Nvivo)

Excel est l'outil qui obtient le taux le plus élevé : environ 27% des personnes interrogées ressentent le besoin d'être accompagnées. On retrouve une proportion relativement similaire à celles des outils de tableur en open source (25%). En ce qui concerne Nvivo, 23% des répondants sont intéressés par un accompagnement à ce logiciel de la famille des CAQDAS. Cette proportion est inférieure de 14 points à celles des répondants ressentant un besoin d'accompagnement pour les logiciels open source de la même famille.

Il est toutefois difficile d'interpréter cet écart dans la mesure où les questions n'ont pas été rédigées de la même manière (Fig. 3.7). La question qui porte sur les logiciels open source est formulée de façon plus générale. Le plus souvent, on




Fig. 3.6: Besoin d'accompagnement aux outils propriétaires

parle d'abord de méthodes avant de citer des noms de logiciels. Par exemple, il est écrit "ressentez-vous le besoin d'un accompagnement aux logiciels d'analyse de réseaux (ex. Gephi) ?" Il est possible alors que le besoin ressenti porte autant sur la méthode, c'est-à-dire l'analyse de réseau, que l'outil, qui est ici Gephi. À l'inverse, dans le cas de la question sur les logiciels propriétaires, les noms d'outils sont directement cités sans référence à une méthode particulière.

Il est possible aussi que cet écart soit lié à une fatigue des participants. Ils répondraient alors "non" par facilité, cette case étant cochée par défaut. Néanmoins, nous ne pouvons pas totalement exclure l'hypothèse que les personnes interrogées aient une appétence plus grande pour les logiciels open source que propriétaires. Il nous semble alors intéressant de comparer ces résultats avec ceux du sondage de la DSIN sur le type de suite bureautique (microsoft, google, outils libres) publicisée par le personnel de l'université.

Enfin, une dizaine de répondants ont fait des suggestions d'outils open source ou propriétaires concernant lesquels ils aimeraient être formés. Ces outils s'inscrivent dans les différentes catégories proposées comme "tropy" (analyses de données qualitatives), jamovi (analyse statistique), les bases de données "orientées graphe" (système de gestion de base de données) ou des outils de traitement du son, des textes ou des images.

3/ Ressentez-vous le besoin d'un accompagnement à l'utilisation de logiciels en open source ?

	Non	Oui, débutant	Oui, avancé
Tableur	☐	☐	☐
Logiciels d'analyse statistique (ex. R – Rstudio)	☐	☐	☐
Python : web-scraping, traitement automatique des langues...	☐	☐	☐
Logiciels d'exploration de textes : analyse, statistique... (ex. Gargantext, Iramuteq, Hyperbase)	☐	☐	☐
Logiciels d'OCR : reconnaissance Optique de Caractère	☐	☐	☐
Logiciels d'analyse de réseaux (ex. Gephi)	☐	☐	☐
Logiciels d'édition numérique en ligne (ex. Odette, Atom)	☐	☐	☐
Logiciel de traitement des données qualitatives, CAQDAS (ex. Taguette)	☐	☐	☐
Logiciels de cartographie thématique (ex. Magrit)	☐	☐	☐
Logiciels de SIG (ex. QGis)	☐	☐	☐
Système de gestion de base de données	☐	☐	☐
Autre	☐	☐	☐

3.1/ Si Autre, précisez lequel (lesquels) ?

4/ Ressentez-vous le besoin d'un accompagnement à l'utilisation de logiciels sous licence ?

	Non	Oui, débutant	Oui, avancé
Excel	☐	☐	☐
SAS	☐	☐	☐
SPSS	☐	☐	☐
STATA	☐	☐	☐
Nvivo	☐	☐	☐
Atlas.ti	☐	☐	☐
Oxygen	☐	☐	☐
ArcGis	☐	☐	☐
Autre	☐	☐	☐

Fig. 3.7: Extrait du questionnaire : l'accompagnement aux logiciels open source et propriétaires

Table 3.8: Suggestion d'accompagnement à des outils open source ou propriétaire

Autres logiciels open source	Autres logiciels propriétaires
logiciel d'analyse des gestes, de l'intonation etc.	Qualtrics, Jamovi
wikidata	Photoshop
Logiciel de reconnaissance de texte manuscrits type Transkribus	Jamovi
modèle linéaire mixte (LMM)	
Bases de données en graphe éventuellement	
Logiciel de traitement d'entretiens et de vidéos	
Anaconda (python), Tropes...	
Tropy	

3.4.3 Services à développer

L'enquête proposait une liste de services en demandant aux participants s'ils considéraient comme utile de les développer. 83% des répondants trouvent ainsi qu'il serait utile de développer les ressources documentaires. Deux d'entre eux écrivent :

“Quand je parle de documentation, je parle d'ouvrages pour la recherche. La bibliothèque est très loin d'être au niveau sur cet aspect, même si elle a un bon fond pour la formation.”

“Il est certain que les ressources documentaires de la bibliothèque sont très pauvres en ce qui concerne la recherche et ne peuvent être utilisées, à mon sens, par des chercheurs d'aujourd'hui.”

On observe des taux équivalents de participants intéressés par le développement d'espaces de travail (83%) ou d'une permanence (81%). Là aussi, un des répondants précise le type de service qui devrait être mis en place :

Apprendre à coder avec l'IA sans devenir soi-même développeur : donc un accès personnalisé à des développeurs (notamment en Python), comme une permanence d'accueil à créneaux fixes.

Le service ayant le moins de succès concerne l'accès à une *SD-Box* et au CASD (Centre d'accès sécurisé aux données). 63% des répondants le jugent tout de même utile.

Pour compléter une question ouverte permettait aux participants de suggérer le développement d'autres services. Quinze personnes y ont répondu. Les propositions portent sur :

- l'accès à des bureaux nominatifs et équipés informatiquement
- des accès wifi pour les stagiaires et les nouveaux collègues dans “un délai raisonnable”
- le développement de services liés à la sécurité des données (accès à un serveur chiffré et des lieux de stockages sécurisés)
- des formations sur l'éthique de la recherche.




Fig. 3.8: Les services à développer

LE TGIR HUMA-NUM ET SES OUTILS

Huma-Num est peu connue des personnes interrogées, même lorsqu'elles ont déjà utilisé les services de l'infrastructure de recherche. En effet, 66 répondants, soit 55% des participants, ne connaissent pas cette infrastructure (Table 4.1). Parmi ces 66 répondants, dix pourtant ont déjà utilisé *Sharedocs*. En tout, 38% des répondants ont déjà stocké des fichiers sur Sharedocs, 18% ont fait des recherches dans *ISIDORE* et 13% ont eu recours à *Nakala*.

Table 4.1: Utilisation de ShareDocs et connaissance d'Huma-Num

	Non, je n'ai jamais utilisé Share-Docs	Oui, j'ai déjà utilisé Share-Docs	All
Non, je ne connais pas Huma-Num	56 (47,06%)	10 (8,4%)	66 (55,46%)
Oui, je connais Huma-Num	18 (15,13%)	35 (29,41%)	53 (44,54%)
Total	74 (62,18%)	45 (37,82%)	119 (100%)

À la question “ressentez-vous le besoin d'un accompagnement à l'utilisation de certains de ces services [d'Huma-Num] ? “ (Fig. 4.1), 39% des répondants ont coché “Oui” pour l'hébergement web. On observe la même proportion en ce qui concerne l'accompagnement à Nakala. 36% ressentent le besoin d'être accompagnés à Sharedocs ainsi qu'à Isidore.

Les tableaux Table 4.2 et Table 4.3 indiquent le besoin d'être accompagné semble lié au fait de connaître Huma-Num et d'avoir utilisé les services déjà une fois. Par exemple, si 61% des personnes interrogées ont ressenti au moins une fois le besoin d'être accompagnées à un service d'Huma-Num, les personnes connaissant Huma-Num sont 66%, tandis que celles ne connaissant pas la TGIR sont 58%. Cette proportion est de 71% pour les personnes ayant utilisé au moins une fois un service d'Huma-Num contre 52% pour celles qui ne l'ont encore jamais fait.

Table 4.2: Le besoin d'être accompagné aux services d'Huma-NUm et la connaissance de la TGIR. Sont considérés comme ayant “besoin d'un accompagnement” les personnes qui ont coché au moins une fois “oui” à la question “ressentez-vous le besoin d'un accompagnement à l'utilisation de certains de ces services [d'Huma-Num] ? “

	N'a pas de besoin d'accompagnement	A besoin d'un accompagnement	Total
Ne connaît pas Huma-Num	42,42	57,58	100
Connaît Huma-Num	33,96	66,04	100
Total	38,66	61,34	100

4/ LA TGIR Huma-Num propose plusieurs services à destination de la communauté de recherche, avez-vous déjà utilisé les services suivants ?

	Non	Oui
Nakala	☐	☐
Isidore	☐	☐
ShareDocs	☐	☐
Hébergement web	☐	☐

5/ Avez-vous utilisé d'autres services de la TGIR Huma-Num ?

	Non	Oui
Stylo	☐	☐
Mattermost	☐	☐
GitLab	☐	☐
Matomo	☐	☐
HNURL	☐	☐
Kanboard	☐	☐

6/ Ressentez-vous bénéficier d'un accompagnement à l'utilisation de certains de ces services ?

	Non	Oui
Nakala (entrepôt de données)	☐	☐
Isidore (moteur de recherche documentaire)	☐	☐
ShareDocs (plateforme de partage de fichiers et de traitement des données)	☐	☐
Hébergement web	☐	☐
Stylo	☐	☐
Mattermost	☐	☐
GitLab	☐	☐
Matomo	☐	☐
HNURL	☐	☐
Kanboard	☐	☐

Fig. 4.1: Les questions consacrées à Huma-Num et ses services




Fig. 4.2: L'utilisation des services Huma-Num




Fig. 4.3: Les besoins en accompagnement aux outils Huma-Num

Table 4.3: Le besoin d’être accompagné aux services d’Huma-Num et leur utilisation. Sont considérés comme ayant “utilisé un service Huma-Num” les personnes qui ont coché au moins une fois “oui” à la question “La TGIR Huma-Num propose plusieurs services à destination de la communauté de recherche, avez-vous déjà utilisé les services suivants ?”

	N'a pas de besoin d'accompagnement	A besoin d'un accompagnement	Total
N'a pas utilisé de service Huma-Num	48,33	51,67	100
A utilisé un service Huma-Num	28,81	71,19	100
Total	38,66	61,34	100

GLOSSAIRE

Gitlab

L'IR* Huma-Num met à disposition des projets de recherche en sciences humaines et sociales (SHS) une instance du logiciel Gitlab. L'instance GitLab d'Huma-Num permet l'hébergement sécurisé et le partage maîtrisé de fichiers, en particulier des fichiers de code informatique (tous langages) selon le protocole de versionnage git.

HNurl

[HNurl.fr](#), pour Huma-Num URL, est un service en ligne permettant de créer des URL courtes non pérennes. Il est développé et maintenu par l'IR* Huma-Num pour l'ensemble de la communauté d'enseignement et de recherche des sciences humaines et sociales. Si la création d'une URL courte dans [HNurl.fr](#) se fait après une connexion via HumanID, l'utilisation de l'URL courte générée est publique, libre et ouverte (par exemple dans un email ou sur les réseaux sociaux).

Isidore

Service proposé par Huma-Num, Isidore est un moteur et un assistant de recherche permettant de découvrir et de trouver des publications, des données numériques et profils de chercheurs et chercheuses en sciences humaines et sociales (SHS) venant du monde entier. Il s'inscrit dans le périmètre des moteurs de recherche académiques favorisant la découvrabilité des publications et des données de la recherche. Il est conçu, développé et hébergé en France.

Kanboard

Kanboard est un logiciel permettant la gestion de projets de recherche fondé sur la méthode organisationnelle "Kanban". Huma-Num propose aux projets de recherche en SHS une instance Kanboard hébergé sur ses serveurs en France. Ce service est à disposition dans la limite des ressources dont dispose Huma-Num.

Mattermost

Huma-Num met à disposition une instance du logiciel Matomo qui permet d'analyser le trafic et l'usage d'un site web hébergé sur les infrastructures d'Huma-Num. Cette alternative aux outils de Google, permet de suivre l'usage d'un site web tout en conservant les données utilisateurs au sein de l'infrastructure Huma-Num. Matomo fonctionne à l'aide d'un "traceur" (un code HTML à ajouter dans le code de vos sites Web) et il est constitué d'une interface web qui permet de visualiser les usages selon divers indicateurs et d'en configurer des nouveaux.

Nakala

Nakala est un entrepôt de données de recherche pour les Sciences Humaines et Sociales certifié entrepôt de données de confiance par le Core Trust Seal en 2026 et par le Comité pour la science ouverte depuis 2024.

SD-Box

La SD-Box est le seul moyen d'accès à l'infrastructure centrale du Centre d'accès sécurisé aux données (CASD) et à l'environnement de travail de l'utilisateur. C'est un dispositif technique conçu et mis au point par le CASD pour répondre aux besoins et contraintes des utilisateurs et déposants de données.

ShareDocs

ShareDocs est un gestionnaire de fichiers mis en oeuvre par l'IR* Huma-Num, sur ses propres serveurs, pouvant être utilisé via un navigateur web, un client WebDAV ou un logiciel de synchronisation de fichiers.

Statistical Software Components

Le dépôt SSC (*Statistical Software Components*), souvent appelé l'*archive de Boston College*, est le principal catalogue de commandes et de packages développés par la communauté d'utilisateurs de Stata.

Stylo

Stylo est un éditeur de texte scientifique simplifiant la rédaction et l'édition d'articles scientifiques en Sciences Humaines et Sociales. Il est hébergé sur <https://stylo.huma-num.fr>. Stylo est un logiciel libre, dont le code est disponible sur github. Il est développé depuis 2020 par la Chaire de recherche du Canada sur les écritures numériques, avec le soutien de l'Université de Montréal, d'Érudit, du Centre de recherche interuniversitaire sur les humanités numériques et de l'IR* Huma-Num dans le cadre l'entente CRIHN-HN, sous licence GPL-3.0.

BIBLIOGRAPHIE

BIBLIOGRAPHY

- [Gro] Maarten Grootendorst. BERTopic: Neural topic modeling with a class-based TF-IDF procedure. URL: <http://arxiv.org/abs/2203.05794> (visited on 2025-04-11), arXiv:2203.05794, doi:10.48550/arXiv.2203.05794.

INDEX

G

Gitlab, [33](#)

H

HNurl, [33](#)

I

Isidore, [33](#)

K

Kanboard, [33](#)

M

Mattermost, [33](#)

N

Nakala, [33](#)

S

SD-Box, [33](#)

ShareDocs, [33](#)

Statistical Software Components, [34](#)

Stylo, [34](#)